34.Ders Notu

İçerik

Regex

Regex: regular expression, bir kural setini belirliyor ve bu kural setini kullanalarak text içinde faydalı işlemler yapıyor. Örneğin eposta adresi kodu bir yazının içinde kodu sınayabiliyor.

Bir yazı içerisinde o yazı setini sağlayan kuralları sınaya biliyor.

Arama işlemlerini *regex engine* ile yapabiliyoruz. Tokenizing araçlarını kullanılıyor.

regex101.com

literal characters: Özel bir karakter grubundal bir şey kullanılmıyorsa bu anlama geliyor *literal* anlamda.

Basit string operasyonlarında regex kullanma

meta character herhangi bir karakteri nitelemk için (newline dışında) bu karakterleri *escape etmemiz gerekiyor*. `[aer]` şeklinde yazdığımızda bunun anlamı 'a' 'e' ve 'r' karakterinden 1'i olabilir.

Rakam karakterleri için `[0-9]` şeklinde yazıyoruz.

`[^` karakteri: bu karakterin anlamı bu karakterlerin dışındaki karakterlerdir.

Quantifiers: Nicelik gösteren grammar aracı olarak kullanılıyor. Bir tokenin arkasına geldiğinde o tokenden kaç tane olduğunu betimliyor.

'?' karakteri: 0 ya da 1 tane olabilir.

`*` karakteri: 0 ya da daha fazla olabilir.

`+` karakteri: 1 ya da daha fazla olabilir.

`{}` karakteri: belirli bir sayıda olabilir. `{2}` şeklinde yazdığımızda 2 tane olabilir. `{2,}` şeklinde yazdığımızda 2 ya da daha fazla olabilir. `{2,4}` şeklinde yazdığımızda 2 ya da 4 tane olabilir.

`\s` whitespace karakteri.

`\d` digit karakteri.

`\w` word karakteri.

`\b` word boundary karakteri.

Parantez Atomu

hem notasyonda öncelik kazandırıyor hem de capture grup denen özelliğe sahip.

back referans: regex stringi içerisinde bulunan bir grubun tekrar kullanılmasını sağlayabiliyor

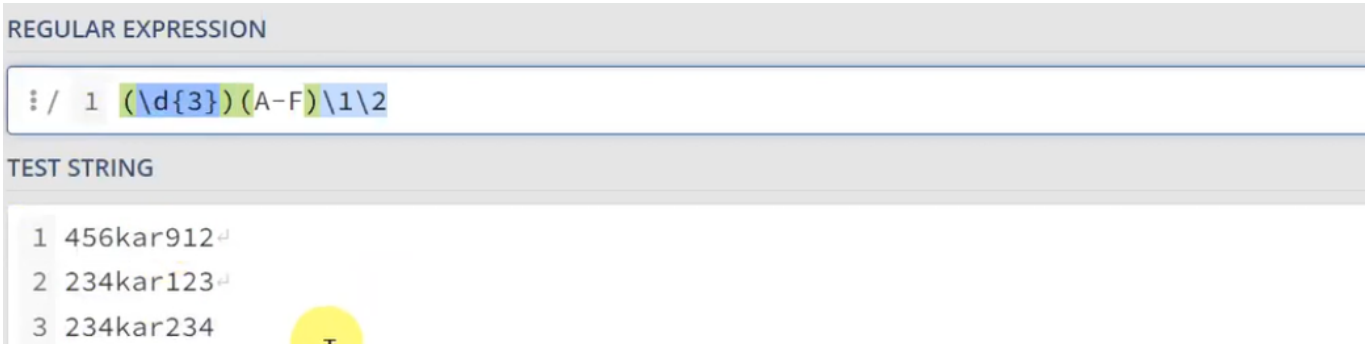


```cpp
struct Vat {

    constexpr Vat(double v) : val{ v } {}

    friend std::ostream& operator<< (std::ostream& oss, const Vat& vat)
    {
        return oss << vat.val;
    }
private:
    double val;
};

template<Vat vat>
int add_vat(int val)
{
    return static_cast<int>(std::round(val * (1 + vat.val)));
}

int main()
{
   /* constexpr Vat v{ 0.2 };
    std::cout << "vat: " << v << '\n';
```

Ayın günlerini aramak için:

kullanılabilir.

Positive lookahead ? işaretinden sonra bir şey var mı diye bakıyor. **Negative lookahead** ?= işaretinden sonra bir şey yok mu diye bakıyor.

bir quanttifier'ın sonuna ? işareti koyduğumuzda o quantifier'ın greedy olmamasını sağlıyoruz. Koşulu sağlayan ilk değeri bulduğunda durucak.

CPP ve Regex

`#include <regex>` kütüphanesi ile regex kullanılabilir.

- regex engine'ı hazırlıyor ve bu engine ile arama işlemleri yapılıyor.
- Mutlaka ve mutlaka bir regex sınıfı türünden bir nesne tanımlanmalı `regex rgx{"cdel"};` şeklinde tanımlanabilir.
- Dikkat etmmemiz gereken şey '' karakteri kullanmamız durumunda escape karakteri olduğu için iki kez yazmamız gerekiyor.
- `regex rgx{"c\\del"};` şeklinde yazılmalı.
- Eğer oluşturulan regex'te bir hata var is exception throw ediyor

`regex_match` ile arama yapıyoruz ve en basit kullanım şekli 2 parametre ile kullanmak örneğin:

```cpp
#include <regex>
#include <iostream>

int main()
{
    std::string s = "ali";
    std::regex rgx{"ali"};
    std::cout << std::regex_match(s,rgx) << "\n";
}
```

```cpp
#include <regex>
#include <iostream>
#include <fstream>

using namespace std;

vector<string> file_to_vec(const string& file_name)
{
    ifstream ifs{ file_name };
    if (!ifs) {
        cerr << "dosya acialmadi\n";
        throw std::runtime_error{ file_name + "cannot open" };
    }
    return vector<string>{istream_iterator<string>{ifs}, {}};
}
```

Bu fonksiyon verilen dosya isminin içerisindeki stringleri vector'e atıyor.

```
 8  vector<string> file_to_vec(const string& file_name) { ...
17
18  int main()
19  {
20      using namespace std;
21
22      auto vec = file_to_vec("words.txt");
23      print("size = {}\n", vec.size());
24
25      regex rgx{ "co.*ion" };
26
27      std::ofstream ofs{ "\\w.*turkey\\.*" };
28      if (!ofs) {
29          std::cerr << "out.txt dosyasi olusturulamadi\n";
30          exit(EXIT_FAILURE);
31      }
32
33      for (const auto& word : vec) {
34          if (regex_match(word, rgx)) {
35              ofs << word << '\n';
36          }
37      }
38
39  }
```

- `regex_search` fonksiyonu ile arama yapılıyor. Buna bir parametre daha ekleniyor. Regex_match'te amaç uydu/uymadı diye kullanabilirizi.
- Eğer biz match ile ilgiili diğer özellikleri istiyorsak o bilgileri kullanmamızı sağlayacak bir nesneye ihtiyacımız var. eğer makul bir neden yoksa out-parametre kullanmamalıyız.

> Out parametre: iletmek istediğimiz parametrelerin değerlerini değiştirmek için kullanılan parametrelerdir. Nesneyi referans semantiği ile gönderiyoruz. Aksi yönde bir sorun yoksa geri dönüş değerini kullanın.

Regex için geçmemiz gereken nesnenin türü `std::smatch` (eğer arama std::string üstünde yapılıyorsa)ya da `cmatch`(aramayı cstring içerisinde yapılıyorsa) olmalı.

Birer `container` ve elemanları submatch, dolayısıyla bu nesne içerisinde bir öğeye eriştiğimiz de bunun türü *submatch* oluyor.

```
int main()
{
    using namespace std;
    smatch sm;
    print("{}\n", sm.empty()); //şu anda boş.
}
```

- Capture grupları: parantez atomları ile oluşturulan gruplar. Bu gruplar içerisindeki elemanlar submatch türünden oluyor.
- Container'daki ilk öğe tam eşleşen öğe oluyor.
- İlk grup 1. elemanı, 2. grup 2. elemanı gibi ilerliyor.

```
int main()
{
    using namespace std;
    string str{"12321321sdfs3141241"};
    regex rgx{R"(\d+)"};
    smatch sm;
    if(regex_match(str, sm,rgx))
    {
        cout << "match\n";
        print("sm.size() = {}\n", sm.size());
        print("sm.length(0) = {}\n", sm.length(0));
        print("sm.position(0) = {}\n", sm.position(0));

    }
    else
    {
        cout << "no match\n";
    }
}
```

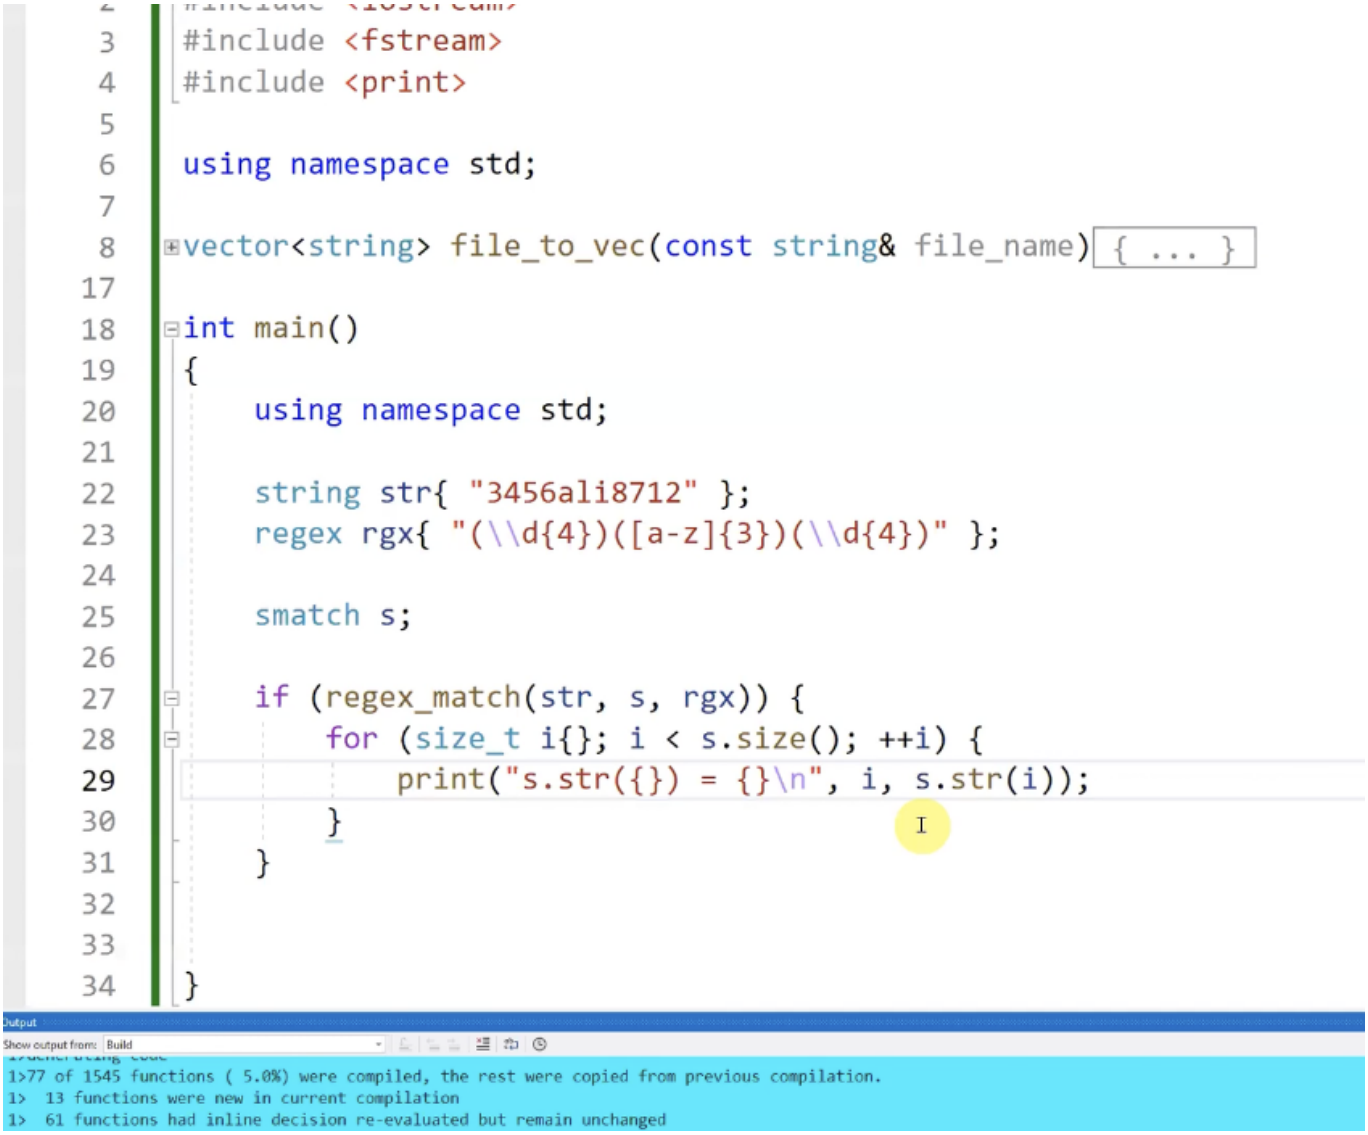

```
#include <fstream>
#include <print>

using namespace std;

vector<string> file_to_vec(const string& file_name) { ... }

int main()
{
    using namespace std;

    string str{ "3456ali8712" };
    regex rgx{ "(\\d{4})([a-z]{3})(\\d{4})" };

    smatch s;

    if (regex_match(str, s, rgx)) {
        for (size_t i{}; i < s.size(); ++i) {
            print("s.str({}) = {}\n", i, s.str(i));
        }
    }


}
```

```
Output
Show output from: Build
1>77 of 1545 functions ( 5.0%) were compiled, the rest were copied from previous compilation.
1>  13 functions were new in current compilation
1>  61 functions had inline decision re-evaluated but remain unchanged
```

regex_search ile arama yaparken prefix match olan kısımdan önce match olmayan kısımları veriyor, suffix match olan kısımdan sonra match olmayan kısımları veriyor.

```
19  {
20      ifstream ifs{ file_name };
21      if (!ifs) {
22          cerr << "dosya acialmadi\n";
23          throw std::runtime_error{ file_name + "cannot open" };
24      }
25
26      vector<string> vec;
27      string sline;
28      while (getline(ifs, sline)) {
29          vec.push_back(move(sline));
30      }
31
32      return vec;
33  }
34
35  int main()
36  {
37      auto vec = get_sentence_vec("sentences.txt");
38
39      regex rgx{ "\\d\\.\\d+" };
40
41
42      for (const auto& s : vec) {
43          if (regex_search(s, rgx)) {
44              cout << s << "                          uygun\n";
45          }
46      }
47
48  }
```